NGS Variant Calling Analysis – Diana Gutiérrez Martínez

1. Introducción

Este informe describe el análisis de datos de secuenciación de ADN utilizando la plataforma *Galaxy*. El objetivo principal fue evaluar la calidad de las lecturas generadas, alinearlas contra el genoma humano de referencia (hg19) e identificar las variantes genéticas presentes en la muestra analizada.

El control de calidad se realizó mediante la herramienta *FASTQC*, seguido del alineamiento de lecturas con *BWA-MEM* y la detección de variantes con *FreeBayes*. Posteriormente, las variantes identificadas fueron anotadas funcionalmente mediante *SnpEff* para evaluar su posible impacto biológico.

Los resultados obtenidos muestran una alta calidad técnica y biológica de los datos de secuenciación, así como la presencia de numerosas variantes genéticas con potencial impacto en la función génica. En conjunto, este análisis demuestra la eficacia del flujo de trabajo utilizado para la obtención de datos genómicos fiables y establece una base sólida para futuros estudios genéticos y funcionales.

2. Preprocesado de los datos

Para determinar la muestra que debía analizarse, se utilizó RStudio y se ejecutó el siguiente código:

```
myseed <- sum(utf8ToInt("dianagutierrez")) set.seed(myseed)
sample_id <- sample(x = 0:9, size = 1)

print(sample_id)

## [1] 9
```

Una vez identificados los archivos *FASTQ* correspondientes a la muestra seleccionada, estos se descargaron desde el repositorio de datos proporcionado. Posteriormente, los archivos *sampleDat9_1.fq* y *sampleDat9_2.fq* se cargaron en la plataforma *Galaxy* mediante la herramienta *Upload File from your computer*, disponible en la sección *Get Data* del panel lateral. Una vez importados, los archivos quedaron disponibles en el historial de trabajo para su posterior análisis.

3. Control de calidad de las lecturas

El control de calidad de las lecturas se realizó utilizando la herramienta *FASTQC Read Quality Reports* disponible en la plataforma *Galaxy*. Se llevaron a cabo dos análisis independientes, uno

para la muestra *sampleDat9_2.fq* y otro para *sampleDat9_1.fq*, con el objetivo de evaluar la calidad de las secuencias obtenidas antes de proceder con el alineamiento y el análisis de variantes.

3.1 Resultados del control de calidad de las lecturas

Tras revisar los archivos HTML generados por *FASTQC*, se observa que ambas muestras presentan una alta calidad de secuencia por base, lo que constituye un resultado positivo. Este indicador es fundamental, ya que una buena calidad de las lecturas garantiza una mayor fiabilidad en la información de cada base secuenciada.

Este aspecto resulta especialmente relevante para el análisis de variantes genéticas, como *single nucleotide polymorphisms* (SNPs) e indels, ya que la precisión en las lecturas es esencial para detectar cambios reales en la secuencia y no errores técnicos derivados del proceso de secuenciación.

Figura 1. Evaluación de la calidad por base de las lecturas mediante FASTQC para las muestras sampleDat9_1.fq y sampleDat9_2.fq.

3.2 Calidad por secuencia de la muestra *sampleDat9_1.fq*

En la gráfica *Per sequence quality scores* del informe generado por *FASTQC* se representa la calidad media de las lecturas individuales. A diferencia de la gráfica de calidad por posición, esta muestra la puntuación promedio de calidad Phred para cada secuencia completa.

El eje X indica la calidad media Phred por lectura, mientras que el eje Y representa el número de lecturas que presentan dicha calidad. La distribución observada se concentra en valores altos de calidad, lo que indica que la mayoría de las lecturas presentan puntuaciones Phred cercanas o superiores a 30. Este resultado sugiere que el proceso de secuenciación generó datos de alta calidad adecuados para el análisis posterior.

En la gráfica *Per sequence GC content*, el eje X representa el porcentaje medio de contenido GC por lectura (%GC), mientras que el eje Y indica el número de secuencias que presentan ese porcentaje de GC. La línea azul representa la distribución GC teórica esperada, mientras que la línea roja muestra la distribución observada en los datos.

La distribución de GC presenta un ligero desplazamiento respecto al valor teórico, pero se mantiene dentro de los rangos esperados, sin evidencias de contaminación o sesgos en la muestra.

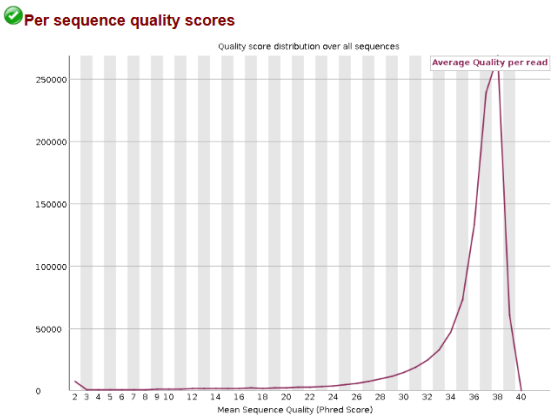

Figura 2. Distribución de la calidad media por secuencia (*Per sequence quality scores)* obtenida con *FASTQC*.

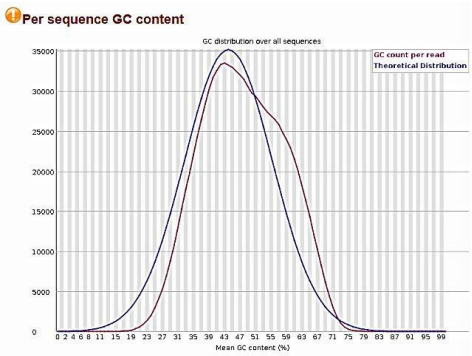

Figura 3. Distribución del contenido GC por secuencia (*Per sequence GC content*) obtenida con *FASTQC*.

3.2 Otros indicadores de calidad.

- ***Per base N content***: No se observaron posiciones con un contenido elevado de bases N, lo que indica una baja incertidumbre en la identificación de nucleótidos durante el proceso de secuenciación.

- ***Sequence length distribution***: La distribución de la longitud de las lecturas se mantiene dentro de los rangos esperados, sin presencia de fragmentos anómalamente cortos o largos.

- ***Sequence duplication levels***: Los niveles de duplicación se encuentran dentro de los valores esperados, lo que sugiere una adecuada diversidad de secuencias y una baja redundancia en las lecturas analizadas.

- ***Overrepresented sequences***: No se detectaron secuencias sobre-representadas en proporciones anómalas, lo que indica ausencia de contaminantes o artefactos derivados del proceso de secuenciación.

- ***Adapter content***: No se identificó presencia significativa de secuencias adaptadoras, lo que sugiere que las lecturas se encuentran libres de contaminación por adaptadores o que el proceso de eliminación de adaptadores fue efectivo.

4. Control de calidad de las lecturas

Para realizar el alineamiento de las lecturas se utilizó como referencia el genoma humano hg19. El proceso se llevó a cabo mediante la herramienta BWA-MEM disponible en la plataforma Galaxy, lo que permitió generar un archivo BAM que contiene las lecturas alineadas junto con la información asociada al mapeo.

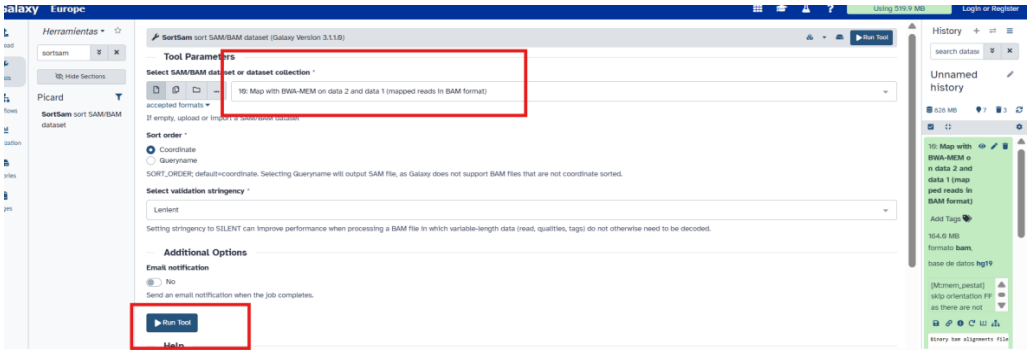

Figura 4. Alineamiento de lecturas al genoma de referencia hg19 mediante la herramienta *BWA-MEM* en la plataforma *Galaxy*.

Posteriormente, las alineaciones obtenidas fueron ordenadas por coordenadas genómicas utilizando la herramienta *SortSam*, con el objetivo de facilitar el análisis posterior de las lecturas mapeadas.

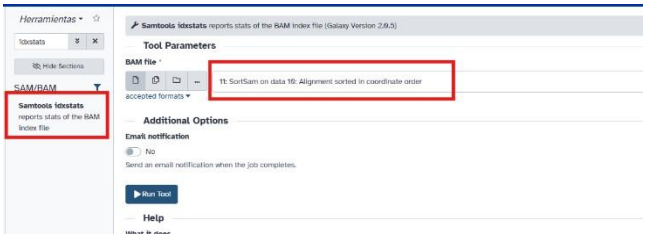

Figura 5. Ordenación de las alineaciones del archivo BAM mediante la herramienta *SortSam* en *Galaxy*.

A continuación, se utilizó la herramienta *Samtools idxstats* para obtener estadísticas de alineamiento, incluyendo el número de lecturas mapeadas y no mapeadas para cada cromosoma presente en el archivo de alineación.

Finalmente, se empleó la herramienta *Samtools flagstat* para generar un resumen estadístico del alineamiento, que incluye información sobre el número total de lecturas mapeadas, lecturas duplicadas y la calidad general del alineamiento.

4.4 Resultados e interpretación

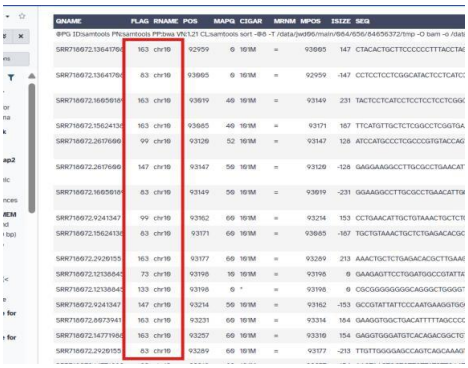

Figura 6. Ejemplo de alineaciones ordenadas por coordenadas en el archivo BAM.

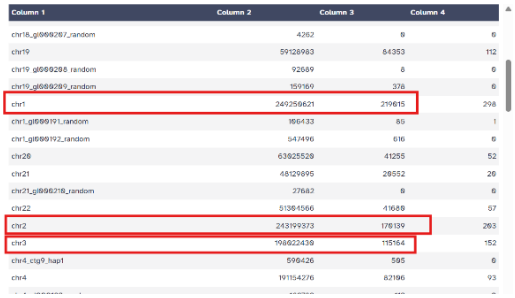

Figura 7. Distribución de lecturas mapeadas por cromosoma obtenida con *Samtools idxstats.*

Una vez realizado el alineamiento, se obtuvo un archivo BAM que contiene las lecturas alineadas y

ordenadas por coordenadas genómicas. Al inspeccionar las primeras líneas del archivo, se observa que las alineaciones comienzan con las correspondientes al cromosoma 10, lo cual es coherente con el orden alfanumérico aplicado durante el proceso de ordenación.

Al analizar la distribución de las lecturas alineadas por cromosoma, se observan coincidencias en todos los cromosomas principales del genoma humano (chr1–chr22, X, Y y MT). Sin embargo, la mayor concentración de lecturas se localiza en los cromosomas chr1, chr2 y chr3, lo cual puede estar relacionado con el mayor tamaño de estas regiones genómicas, ya que se encuentran entre los cromosomas más largos del genoma humano.

Asimismo, se detectaron algunas lecturas alineadas en secuencias denominadas *random* o regiones no asignadas (por ejemplo, chrUn, chrM o chrX_random), aunque en cantidades muy reducidas. Este resultado es esperado, ya que estas regiones suelen contener secuencias ambiguas o repetitivas, y un bajo número de alineamientos en ellas indica una buena especificidad del proceso de mapeo.

Al analizar los resultados obtenidos con *Samtools flagstat*, se observa que:

```
2000466 + 0 in total (QC-passed reads + QC-failed reads)
2000000 + 0 primary
0 + 0 secondary
466 + 0 supplementary
0 + 0 duplicates
0 + 0 primary duplicates
1996015 + 0 mapped (99.78% : N/A)
1995549 + 0 primary mapped (99.78% : N/A)
2000000 + 0 paired in sequencing
1000000 + 0 read1
1000000 + 0 read2
1978972 + 0 properly paired (98.95% : N/A)
1993040 + 0 with itself and mate mapped
2509 + 0 singletons (0.13% : N/A)
2356 + 0 with mate mapped to a different chr
1555 + 0 with mate mapped to a different chr (mapQ>=5)
```

Figura 8. Resumen estadístico del alineamiento obtenido con *Samtools flagstat.*

Hay una alta calidad del mapeo, 99.78% lecturas mapeadas. Y observo un *properly paired* de 98.95%, es decir lecturas emparejadas correctamente alineades.

5. Identificación de variantes genéticas

Para la identificación de variantes genéticas, se generó inicialmente un archivo *pileup* a partir del archivo BAM mediante la herramienta *Generate pileup from* BAM *dataset*. Este formato permite examinar las bases alineadas en cada posición del genoma, así como calcular la cobertura de lectura e identificar posibles variantes de secuencia, como SNPs e indels.

Posteriormente, el archivo *pileup* fue filtrado utilizando la herramienta *Filter pileup on coverage and SNPs*. En este paso se descartaron las posiciones con una cobertura inferior a 10 lecturas y una calidad menor a 20. El proceso de filtrado se realizó en dos ocasiones con el fin de generar un archivo que contuviera únicamente las variantes detectadas y otro con todas las posiciones analizadas.

A continuación, las variantes genéticas fueron identificadas mediante la herramienta *FreeBayes*

(*Bayesian Genetic Variant Detector*), la cual permite detectar variantes a partir de los datos de alineamiento y asignar una puntuación de calidad a cada una de ellas. Este análisis se aplicó sobre el archivo BAM previamente ordenado por coordenadas genómicas.

Finalmente, los resultados obtenidos se visualizaron utilizando el *UCSC Genome Browser*, lo que permitió inspeccionar las variantes detectadas en el contexto del genoma de referencia.

5.1 Resultados

Column 1	Column 2	Column 3	Column 4	Column 5	Column 6
chr19	92959	C		1 ^L	:
chr19	92960	C		1 T	+
chr19	92961	A		1 .	1
chr19	92962	C		1 .	=
chr19	92963	A		1 .	D
chr19	92964	C		1 .	D
chr19	92965	T		1 .	D
chr19	92966	G		1 .	D
chr19	92967	C		1 .	H
chr19	92968	T		1 .	H
chr19	92969	T		1 .	H
chr19	92970	C		1 .	H
chr19	92971	C		1 .	H
chr19	92972	C		1 .	I
chr19	92973	C		1 .	I
chr19	92974	C		1 .	I
chr19	92975	C		1 .	I
chr19	92976	T		1 .	I
chr19	92977	T		1 .	@

Figura 9. Fragmento del archivo *pileup* generado a partir del archivo BAM.

En los resultados obtenidos se observan 10 columnas, cada una con un significado específico relacionado con la información del alineamiento. La columna 1 indica el cromosoma donde se encuentra la posición analizada, mientras que la columna 2 corresponde a la posición genómica dentro del genoma de referencia. La columna 3 muestra la base de referencia presente en dicha posición, y la columna 4 representa la base consenso observada en las lecturas alineadas.

La columna 5 indica el número de lecturas que cubren esa posición, lo que se conoce como cobertura de lectura. Las columnas 6 y 8 contienen información adicional relacionada con las variantes detectadas, como la calidad de deleciones u otros eventos de variación. La columna 9 muestra las bases observadas en las lecturas alineadas, mientras que la columna 10 corresponde al valor de Phred score, que refleja la calidad de la base identificada.

Al analizar las variantes genéticas detectadas en el archivo generado a partir del alineamiento ordenado (*SortSam*), se identificó un total de 29.813 variantes genéticas al comparar las lecturas alineadas con el genoma de referencia hg19. Estos resultados evidencian la presencia de múltiples variantes, incluyendo SNPs (*single nucleotide polymorphisms*) e indels.

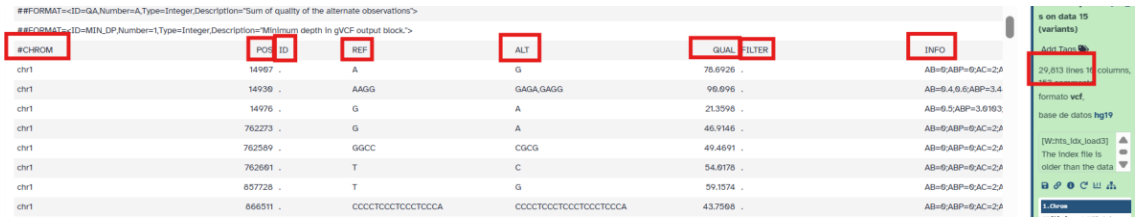

##FORMAT=<ID=QA,Number=A,Type=Integer,Description="Sum of quality of the alternate observations">

##FORMAT=<ID=MIN_DP,Number=1,Type=Integer,Description="Minimum depth in gVCF output block.">

#CHROM	POS	ID	REF	ALT	QUAL	FILTER	INFO
chr1	14967	.	A	G	78.6926	.	AB=0;ABP=0;AC=2;A
chr1	14939	.	AAGG	GAGA,GAGG	96.996	.	AB=0.4,0.6;ABP=3.4
chr1	14976	.	G	A	21.3598	.	AB=0.5;ABP=3.6193;
chr1	762273	.	G	A	46.9146	.	AB=0;ABP=0;AC=2;A
chr1	762589	.	GGCC	CGCG	49.4691	.	AB=0;ABP=0;AC=2;A
chr1	762691	.	T	C	54.6178	.	AB=0;ABP=0;AC=2;A
chr1	857728	.	T	G	59.1574	.	AB=0;ABP=0;AC=2;A
chr1	866511	.	CCCCTCCCTCCCTCCCA	CCCCTCCCTCCCTCCCTCCCA	43.7568	.	AB=0;ABP=0;AC=2;A

Figura 10. Ejemplo del archivo de variantes en formato *VCF* generado mediante *FreeBayes*, mostrando las principales columnas que describen la posición y características de las variantes detectadas.

En el archivo de resultados generado se observan varias columnas que describen la información asociada a cada variante detectada.

- **CHROM:** cromosoma en el que se localiza la variante dentro del genoma.
- **POS:** posición exacta de la variante en el genoma de referencia.
- **REF:** base o nucleótido presente en el genoma de referencia.
- **ALT:** base o nucleótido alternativo observado en las lecturas secuenciadas.
- **QUAL:** puntuación de calidad asociada a la variante, que indica la confianza estadística de la detección.
- **INFO:** campo que contiene información adicional sobre la variante, incluyendo parámetros relacionados con la profundidad de lectura, frecuencia alélica u otras métricas del análisis.

Estos resultados permiten identificar con precisión las variantes genéticas presentes en la muestra analizada y constituyen la base para su posterior anotación funcional y evaluación de impacto biológico.

6. Visualización de los resultados intermedios mediante Genome Browse.

Para visualizar el alineamiento de las lecturas, se utilizó el icono de visualización disponible en el archivo BAM correspondiente al *alignment sorted in coordinate order* generado previamente. Al seleccionar esta opción, la plataforma Galaxy ofrece diferentes herramientas de visualización que permiten explorar los datos de alineamiento.

6.1 UCSC Genome Browser

Esta herramienta permite visualizar el alineamiento de las lecturas directamente en el navegador web, facilitando la comparación con el genoma de referencia y la inspección de regiones específicas del genoma.

6.2 BAM.iobio

La herramienta *bam.iobio* permite obtener estadísticas del archivo BAM de forma interactiva, como la tasa de mapeo, la profundidad de cobertura y otras métricas relacionadas con la calidad del alineamiento. Para explorar los datos con mayor detalle, es posible ampliar regiones específicas del genoma mediante la selección de subconjuntos de lecturas.

6.3 Interactive Genomics Viewer (IGV)

El *Interactive Genomics Viewer (IGV)* es una aplicación de escritorio que permite visualizar el alineamiento de las lecturas de forma detallada. Esta herramienta facilita la inspección manual de regiones genómicas, la visualización de variantes y la evaluación de la calidad del alineamiento.

7. Resultados de UCSC y BAM.iobio

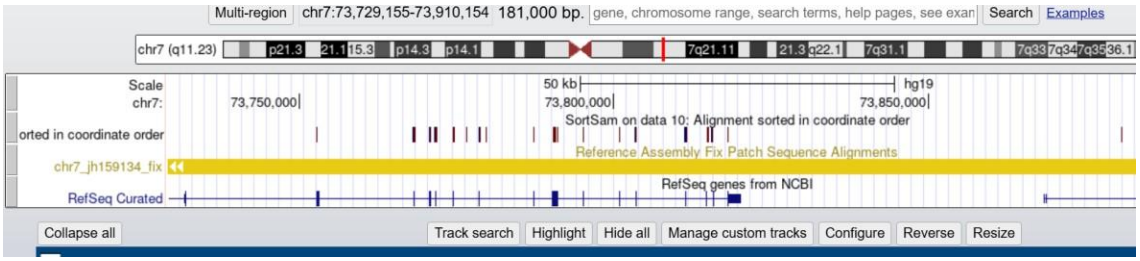

Figura 11. Visualización del alineamiento de lecturas en el *UCSC Genome Browser*, mostrando regiones con alta cobertura de secuenciación en el cromosoma 7.

En la visualización mediante *UCSC Genome Browser* se observa una alta densidad de lecturas alineadas en regiones del cromosoma 7, lo que refleja una buena cobertura de secuenciación.

El análisis del archivo BAM generado tras el alineamiento se realizó utilizando la herramienta *bam.iobio*, la cual permite una visualización rápida y eficiente de estadísticas clave del archivo de alineamiento directamente desde el navegador. Esta herramienta facilita la exploración de diferentes métricas de calidad, como la profundidad de cobertura, la tasa de mapeo y la distribución de las lecturas a lo largo de los cromosomas.

Mediante *bam.iobio* fue posible observar la cobertura de lecturas en distintas regiones del genoma, evidenciando alineamientos distribuidos a lo largo de todos los cromosomas analizados.

Los principales resultados obtenidos fueron los siguientes:

Figura 12. Estadísticas generales del alineamiento visualizadas mediante *bam.iobio*, mostrando la tasa de lecturas mapeadas y la distribución de la cobertura.

El análisis realizado con *bam.iobio* mostró que el 98,4 % de los pares de lecturas (*paired-end*) presentan ambos fragmentos correctamente alineados, lo que refleja una adecuada calidad en la preparación de la librería y una fragmentación genómica eficiente.

Asimismo, el 0,7 % de las lecturas fueron clasificadas como *singletons*, es decir, casos en los que solo uno de los fragmentos del par logró alinearse. Este valor es bajo y se encuentra dentro de los rangos esperados para datos de secuenciación de buena calidad.

Por otro lado, no se detectaron lecturas duplicadas (0 %), lo que indica ausencia de sobreamplificación o artefactos derivados de la PCR durante la preparación de la muestra. Este resultado es favorable, ya que una elevada duplicación puede introducir sesgos en los análisis cuantitativos y en la detección de variantes.

En cuanto a la orientación de las lecturas, el 49,2 % se alineó en la hebra directa (*forward strand*), lo que refleja una distribución equilibrada entre ambas hebras, tal como se espera en protocolos de secuenciación no direccionales.

En conjunto, estas métricas indican que el alineamiento presenta una alta calidad, con una elevada proporción de lecturas correctamente mapeadas, una adecuada concordancia entre pares, ausencia de duplicaciones y una distribución equilibrada entre hebras. Estos resultados respaldan la fiabilidad del conjunto de datos y permiten continuar con confianza hacia las etapas posteriores del análisis, como la detección y anotación de variantes genéticas.

8. Filtrado y anotación de variantes.

Para la anotación funcional de las variantes genéticas identificadas previamente con *FreeBayes*, se utilizó la herramienta *SnpEff* mediante el comando eff. Este programa permite añadir información biológica relevante a cada variante detectada mediante la comparación con bases de datos de referencia.

SnpEff proporciona información sobre la localización de cada variante en el genoma y su posible impacto funcional. Por ejemplo, permite determinar si una variante se encuentra dentro de un gen conocido, en regiones reguladoras o en zonas no codificantes del genoma. Asimismo, la herramienta estima el posible efecto de cada variante sobre la función proteica, identificando cambios que puedan alterar la secuencia de aminoácidos o generar codones de parada prematuros.

Además, SnpEff genera un informe en formato HTML que resume los resultados del análisis, incluyendo el tipo de variantes detectadas, su impacto potencial y las regiones genómicas afectadas.

Tras el proceso de filtrado y anotación se identificaron 29.895 variantes genéticas. Entre los principales tipos de variantes detectadas se encuentran:

- **MNP (Multiple Nucleotide Polymorphisms):** 662 variantes.
- **INS (Inserciones):** 639 variantes.
- **DEL (Deleciones):** 963 variantes.
- **MIXED:** 90 variantes complejas que combinan diferentes tipos de cambios.

En cuanto a las anotaciones funcionales, los resultados más relevantes incluyen:

- **Missense variants:** 16.107 variantes que producen un cambio en la secuencia de aminoácidos de la proteína.
- **Nonsense variants:** 282 variantes que generan un codón de parada prematuro.
- **Silent variants:** 15.003 variantes sinónimas que no alteran la secuencia de la proteína.

Las variantes también se clasificaron según su localización en diferentes regiones del genoma:

Variantes con posible impacto en regiones codificantes:

- **Variantes *missense*:** 16.107
- **Variantes *nonsense*:** 282

Variantes en regiones reguladoras o no codificantes:

- **Variantes en región 3' UTR:** 5.359
- **Variantes en región 5' UTR:** 2.165
- **Variantes intrónicas:** 72.506

- **Variantes en exones de transcritos no codificantes:** 18.274
- **Variantes cercanas a sitios de splicing:** 4.895

Estos resultados permiten identificar las variantes genéticas presentes en la muestra y evaluar su posible impacto funcional en diferentes regiones del genoma.

Number of effects by type and region

Type

Type (alphabetical order)	Count	Percent
3_prime_UTR_variant	5,359	3.88%
5_prime_UTR_premature_start_codon_gain_variant	243	0.176%
5_prime_UTR_variant	1,922	1.391%
conservative_inframe_deletion	64	0.046%
conservative_inframe_insertion	45	0.033%
disruptive_inframe_deletion	30	0.022%
disruptive_inframe_insertion	27	0.02%
frameshift_variant	528	0.382%
initiator_codon_variant	5	0.004%
intergenic_region	2,340	1.694%
intragenic_variant	6	0.004%
intron_variant	72,506	52.489%
missense_variant	16,107	11.66%
non_coding_transcript_exon_variant	18,274	13.229%
splice_acceptor_variant	159	0.115%
splice_donor_variant	221	0.16%
splice_region_variant	4,895	3.544%
start_lost	24	0.017%
start_retained_variant	6	0.004%
stop_gained	290	0.21%
stop_lost	23	0.017%
stop_retained_variant	14	0.01%
synonymous_variant	15,047	10.893%

Region

Type (alphabetical order)	Count	Percent
EXON	49,634	37.353%
INTERGENIC	2,340	1.761%
INTRON	68,567	51.601%
SPLICE_SITE_ACCEPTOR	159	0.12%
SPLICE_SITE_DONOR	199	0.15%
SPLICE_SITE_REGION	4,450	3.349%
TRANSCRIPT	6	0.005%
UTR_3_PRIME	5,359	4.033%
UTR_5_PRIME	2,165	1.629%

Figura 13. Distribución de variantes por tipo de efecto y región genómica (*SnpEff*).

8.1 Análisis de variantes y patrones de mutación

Se analizaron las frecuencias alélicas de las variantes detectadas, obteniendo diferentes estadísticos descriptivos que permiten caracterizar la distribución de las mutaciones presentes en la muestra.

En primer lugar, se evaluaron las características de las inserciones y deleciones (*indels*). Los resultados muestran que la mayoría de estas variantes presentan tamaños reducidos, con una longitud máxima de 14 nucleótidos, lo cual es consistente con lo observado en estudios de variación genética en genomas eucariotas. Además, la elevada frecuencia alélica media indica que muchas de estas variantes se encuentran presentes en una proporción significativa de las lecturas analizadas.

Posteriormente, se realizó un análisis detallado de las sustituciones de bases en los *SNPs* detectados, con el objetivo de identificar patrones de mutación recurrentes. Para ello, se calcularon las frecuencias de los dos tipos principales de sustituciones nucleotídicas:

- **Transiciones (Ti): 31.472**, que corresponden a sustituciones entre bases del mismo tipo químico (purina ↔ purina: A↔G, o pirimidina ↔ pirimidina: C↔T).

- **Transversiones (Tv): 13.495**, que corresponden a sustituciones entre purinas y pirimidinas (A↔C, A↔T, G↔C, G↔T).

A partir de estos valores se calculó la relación transición/transversión (Ts/Tv), obteniendo un valor de 2.33.

Este valor se encuentra dentro del rango esperado para datos de secuenciación de alta calidad en organismos eucariotas, donde la relación Ts/Tv suele situarse entre 2.0 y 3.0 en regiones codificantes. Por tanto, estos resultados sugieren que las variantes identificadas siguen patrones biológicamente plausibles y que no existe evidencia significativa de contaminación ni de un exceso de falsos positivos en el proceso de detección de variantes.

Finalmente, se generó una matriz de cambios de codones, que permite visualizar las transformaciones entre codones causadas por las mutaciones detectadas y analizar la frecuencia de cada tipo de sustitución.

Codon changes

How to read this table:
- Rows are reference codons and columns are changed codons. E.g. Row 'AAA' column 'TAA' indicates how many 'AAA' codons have been replaced by 'TAA' codons.
- Red background colors indicate that more changes happened (heat-map).
- Diagonals are indicated using grey background color
- WARNING: This table may include different translation codon tables (e.g. mamalian DNA and mitochondrial DNA).

	-	AAA	AAC	AAG	AAT	ACA	ACC	ACG	ACT	AGA	AGC	AGG	AGT	ATA	ATC	ATG	ATT	CAA	CAC	CAG	CAT	CCA	CCC	CCG	CCT	CGA	CGC	CGG	CGT	CTA
-				3	10	6		2	5	7			3	4	6			5		5		1	3		3					
AAA	25	14	25	199	30	20				84		3		3				17												
AAC	5	24		20	314		29				104				19				8											
AAG	19	140	57	5	52			26				110				17		2		12				2						
AAT	19	29	294	17	2				7				182		2		26				21									
ACA	17	30	2			1	60	369	31	16				77								15								
ACC	11		31			58	1	78	253		34				79							5	38							
ACG				27		352	39		27			1		1		140								8						
ACT	2				32	48	266	31	3		1	1	48		2		96								16					
AGA	7	65				19				2	10	123	22	24												22				
AGC	6		127		2		63			35	2	19	216		39												1			
AGG	9			82				3		83	28		24			9				1								45		
AGT	15	1			128				34	7	152	18					17												6	
ATA	5	11				54				4				1	37	62	6													2
ATC	2		47				65		6		3			56	2	14	187													
ATG	13			22		1		191				3	1	82	26	6	42													
ATT	12				43				59				11	30	190	21														
CAA	18	36																8	12	221	18	15				102		2		16
CAC	18		41															11		39	242		13	1			114		1	
CAG	16			84		4						1						271	48	1	37			30				237		1
CAT					26													15	235	14					10		3		131	
CCA	3					45	1											22	4			15	41	280	21	17				51
CCC	15						20								6				23	3		43	5	65	248		15			
CCG								17												12		317	46		43			15		

Figura 14. Matriz de cambios de codones generada a partir de las variantes detectadas, mostrando la frecuencia de sustituciones entre codones.

En la matriz de cambios de codones, cada fila representa el codón original, mientras que cada columna indica el codón resultante tras la mutación. Los valores numéricos muestran la frecuencia con la que se produce cada sustitución entre codones. La escala de colores refleja la frecuencia de estos cambios: los colores verdes indican sustituciones poco frecuentes, mientras que los tonos rojos o marrones representan cambios más frecuentes.

Por ejemplo, el cambio ACG → ACC (382 eventos) indica que numerosas mutaciones transforman el codón ACG en ACC. Ambos codones codifican el aminoácido treonina, por lo que se trata de una mutación sinónima, que no altera la secuencia de la proteína.

Por otro lado, el cambio ATG → ATA (271 eventos) representa una sustitución entre el codón ATG, que codifica para metionina y actúa como codón de inicio de traducción, y ATA, que codifica para isoleucina. Este tipo de cambio corresponde a una mutación no sinónima, que puede alterar la secuencia

de la proteína y potencialmente afectar su función.

El análisis de esta matriz permite identificar patrones recurrentes de sustitución de codones y evaluar el posible impacto funcional de las mutaciones detectadas en el genoma analizado.

9. Discusión y conclusiones

El análisis realizado mediante la plataforma *Galaxy* permitió obtener datos de alta calidad y resultados fiables para el estudio genómico. Las lecturas presentaron puntuaciones Phred promedio superiores a 30, lo que indica una secuenciación precisa y adecuada para el análisis posterior. Asimismo, el contenido GC mostró una ligera desviación hacia valores superiores a los teóricos, aunque sin evidencias de contaminación ni sesgos significativos, lo que sugiere que las muestras representan correctamente el genoma analizado.

El alineamiento de las lecturas frente al genoma de referencia hg19 fue altamente eficiente, alcanzando un 99,78 % de lecturas mapeadas y un 98,95 % de pares correctamente alineados. Además, la ausencia de lecturas duplicadas y la baja proporción de *singletons* (0,7 %) reflejan una biblioteca de secuenciación diversa y libre de artefactos técnicos, lo cual es fundamental para garantizar la fiabilidad del análisis.
En total se identificaron 29.895 variantes genéticas, incluyendo SNPs, inserciones, deleciones y variantes complejas. La relación transiciones/transversiones (Ts/Tv) fue de 2,33, valor que se encuentra dentro del rango esperado para datos de secuenciación humana de alta calidad, lo que respalda la fiabilidad de las variantes detectadas. La anotación funcional reveló la presencia de 16.107 variantes missense y 282 variantes nonsense, que potencialmente podrían afectar la función proteica, además de numerosas variantes localizadas en regiones reguladoras y no codificantes del genoma.

Las herramientas de visualización utilizadas, como *UCSC Genome Browser* y *bam.iobio*, confirmaron una adecuada cobertura de las lecturas y un alineamiento equilibrado a lo largo del genoma, mostrando un 98,4 % de pares correctamente alineados y ausencia de duplicaciones significativas.

En conjunto, estos resultados validan la robustez del flujo de trabajo implementado en *Galaxy*, demostrando que se trata de una plataforma eficiente y reproducible para el análisis de datos de secuenciación de nueva generación. Los resultados obtenidos indican que la muestra analizada presenta una alta calidad técnica y biológica, y que las variantes identificadas podrían constituir una base relevante para estudios funcionales posteriores, como análisis de expresión génica o estudios de asociación genética.